

LIGA DE MERCADO FINANCEIRO
UFU

LIGA DE MERCADO FINANCEIRO — UFU

Diretoria de Pesquisa — Ementa 2026.1

Núcleo de Análise Quantitativa

Quant

Arthur Pires Lopes

Diretor de Pesquisa

Engenharia Elétrica — 6° Período

Challenge de referência: **Itaú Quant Challenge**

LIGA DE MERCADO
FINANCEIRO
UFU

1. Objetivo do Núcleo

O Núcleo de Análise Quantitativa tem como missão **formar membros em métodos quantitativos aplicados a finanças**, desenvolvendo competências em programação, estatística, modelagem e gestão de risco que se traduzam em **performance real em challenges** — em especial o Itaú Quant Challenge.

O núcleo preenche uma lacuna na Liga: atualmente não há espaço estruturado para quem quer trabalhar com **dados, modelos e automação** no contexto de mercados. A proposta é criar esse espaço com processo claro, entregas aplicadas e padrão de qualidade reproduzível.

Ao final do ciclo, o membro será capaz de:

- Coletar, tratar e analisar dados financeiros com Python;
- Construir e validar estratégias quantitativas com backtesting rigoroso;
- Mensurar e gerenciar risco de portfólio (VaR, CVaR, drawdown, stress test);
- Aplicar técnicas de Machine Learning a problemas financeiros;
- Desenvolver e operar bots de trading algorítmico;
- Comunicar resultados com clareza técnica (relatórios e notebooks documentados).

2. Pré-requisitos e Ferramentas

2.1. Pré-requisitos recomendados

- Noções básicas de programação (qualquer linguagem; Python é preferencial);
- Estatística descritiva (média, variância, distribuições);
- Interesse genuíno por mercado financeiro e métodos quantitativos.

Observação: não é necessário dominar todos os pré-requisitos — as primeiras aulas nivelam a base. O mais importante é disposição para estudar e praticar.

2.2. Stack Técnico

Ferramenta	Uso
Python 3.10+	Linguagem principal
Jupyter Notebook / VS Code	Ambiente de desenvolvimento
pandas / NumPy	Manipulação e cálculo numérico
Matplotlib / Plotly	Visualização de dados
SciPy / statsmodels	Estatística e séries temporais
scikit-learn	Machine Learning
backtrader / bt / vectorbt	Backtesting de estratégias
yfinance / APIs	Coleta de dados de mercado
Git + GitHub	Versionamento e repositório

3. Cronograma de Aulas — 12 Semanas

O ciclo é composto por **12 encontros quinzenais**, alternando teoria e prática. Cada aula tem duração estimada de 1h30 a 2h. O cronograma está organizado em três blocos progressivos:

Bloco 1 — Fundamentos (Semanas 1–4)

Semana	Tema	Conteúdo
1	Python para Finanças I	Ambiente de trabalho (Jupyter, VS Code, Git). Introdução a `pandas` e `NumPy`. Importação e manipulação de séries de preços. Cálculo de retornos simples e log-retornos.
2	Python para Finanças II	Coleta de dados via `yfinance` e APIs. Tratamento de dados faltantes. Visualização de séries temporais com `Matplotlib` e `Plotly`. Análise exploratória de ativos brasileiros e internacionais.
3	Estatística Aplicada	Estatística descritiva de retornos. Distribuições (normal, t-Student, caudas pesadas). Testes de hipótese (normalidade, estacionariedade). Correlação e covariância entre ativos.
4	Séries Temporais	Conceito de estacionariedade e testes ADF. Autocorrelação (ACF/PACF). Modelos ARIMA. Modelagem de volatilidade: GARCH. Aplicação prática em dados reais.

Bloco 2 — Risco e Backtesting (Semanas 5–8)

Semana	Tema	Conteúdo
5	Gestão de Risco I	Value at Risk (VaR): paramétrico, histórico e por simulação de Monte Carlo. Conditional VaR (CVaR / Expected Shortfall). Drawdown máximo e métricas de cauda.
6	Gestão de Risco II	Teoria de portfólio de Markowitz. Fronteira eficiente e otimização média-variância. Diversificação e matriz de correlação. Stress testing e análise de cenários.
7	Backtesting I	Fundamentos de backtesting. Métricas de performance: Sharpe, Sortino, Calmar, Treynor. Vieses comuns: *look-ahead bias*, *survivorship bias*, *overfitting*. Introdução ao framework `backtrader`.
8	Backtesting II	Implementação prática de estratégias (momentum, mean reversion, breakout). Walk-forward analysis e validação out-of-sample. Relatório de backtest padronizado. **Entrega intermediária.**

Bloco 3 — Machine Learning, Bots e Projeto Final (Semanas 9–12)

Semana	Tema	Conteúdo
9	Machine Learning I	Regressão linear e logística aplicadas a finanças. Feature engineering com dados de mercado (retornos defasados, volatilidade, indicadores técnicos). Validação temporal (*time-series split*).
10	Machine Learning II	Modelos ensemble: Random Forest, Gradient Boosting (XGBoost / LightGBM). Seleção de features e regularização. Overfitting em finanças: por que modelos complexos falham. Interpretação de resultados.
11	Algoritmos de Trading	Lógica de bots de trading. Gestão de ordens (limit, market, stop). Simulação e paper trading. Integração com APIs de corretoras. Custos de transação e slippage.
12	Projeto Final	Apresentação da estratégia completa: tese → modelo → backtest → resultado. Cada membro/grupo defende sua abordagem. Feedback coletivo e documentação para o repositório da Liga.

4. Metodologia

- **Formato:** aulas quinzenais teórico-práticas (alternando com os demais núcleos da Diretoria de Pesquisa), com duração de 1h30 a 2h.
- **Dinâmica:** cada encontro combina exposição conceitual curta (∼30 min) com exercício *hands-on* em Jupyter Notebook (∼60 min). O foco é **aprender fazendo**.
- **Mini-entregas:** a cada 2–4 semanas, os membros submetem um notebook documentado com a aplicação prática do bloco. Isso garante cadência e evita acúmulo no final.
- **Discussão de referências:** ao longo do ciclo, papers e capítulos de livros são indicados como leitura complementar e discutidos brevemente no início das aulas.
- **Repositório compartilhado:** todo material (slides, notebooks, datasets, templates) ficará versionado no GitHub da Liga, criando acervo reaproveitável para os próximos semestres.
- **Suporte assíncrono:** grupo dedicado para dúvidas, compartilhamento de materiais e discussões entre encontros.

5. Entregas e Avaliação

5.1. Entregas esperadas

#	Entrega	Descrição	Semana
1	Análise Exploratória	Notebook com coleta, tratamento e visualização de dados de pelo menos 5 ativos. Estatísticas descritivas e correlação.	4
2	Relatório de Risco	Cálculo de VaR, CVaR e drawdown para um portfólio. Otimização de Markowitz com fronteira eficiente.	6
3	Backtest Completo	Implementação de uma estratégia quantitativa com backtest rigoroso, métricas de performance e análise de robustez.	8
4	Projeto Final	Estratégia completa (tese + modelo + backtest + resultado), apresentada e documentada.	12

5.2. Critérios de avaliação (rubrica)

Cada entrega será avaliada em 4 dimensões com peso igual:

1. **Rigor técnico:** os métodos estão corretos? Os pressupostos foram verificados? O código é limpo e funcional?
2. **Clareza:** o notebook é auto-explicativo? Há narrativa conectando as etapas? Gráficos estão rotulados?
3. **Reprodutibilidade:** outra pessoa consegue rodar o notebook do zero e obter os mesmos resultados?
4. **Interpretação:** os resultados foram discutidos de forma crítica? Limitações foram apontadas? Há conclusão objetiva?

Nota: a meta não é perfeição — é *progresso consistente*. Entregar no prazo com estrutura razoável vale mais do que entregar atrasado com código impecável.

6. Referências e Recursos

6.1. Livros recomendados

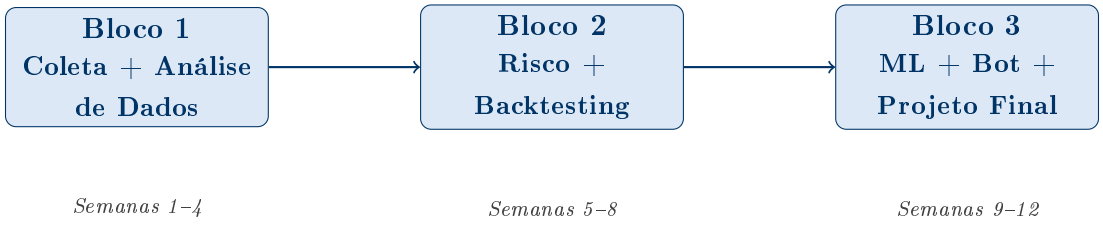
1. **Marcos López de Prado** — *Advances in Financial Machine Learning* (Wiley, 2018).
   Referência central em ML aplicado a finanças. Cobre backtesting, feature engineering, overfitting e meta-labeling.
2. **Ernest P. Chan** — *Quantitative Trading: How to Build Your Own Algorithmic Trading Business* (Wiley, 2nd ed.).
   Guia prático para construção de estratégias quantitativas, gestão de risco e operação de bots.
3. **Yves Hilpisch** — *Python for Finance: Mastering Data-Driven Finance* (O'Reilly, 2018).
   Cobertura completa de Python aplicado a dados financeiros, derivativos e simulação.
4. **Stefan Jansen** — *Machine Learning for Algorithmic Trading* (Packt, 2nd ed., 2020).
   Foco em pipelines completos de ML para trading, com código reproduzível em Python.
5. **Andrew Ang** — *Asset Management: A Systematic Approach to Factor Investing* (Oxford, 2014).
   Base teórica de fatores de risco, alocação e gestão de portfólio.

6.2. Recursos online

- **QuantConnect / Lean** — plataforma open-source de backtesting e trading algorítmico.
- **Kaggle** — datasets financeiros e competições de ML aplicado.
- **Documentação oficial:** `pandas`, `scikit-learn`, `backtrader`, `statsmodels`.
- **YouTube:** canais de finanças quantitativas (QuantPy, Sentdex, The Trading Scientist).

7. Alinhamento com Challenges

O cronograma do Núcleo Quant foi desenhado para **maximizar a preparação para o Itaú Quant Challenge** e competições similares. A progressão dos blocos espelha a estrutura típica de um desafio quant:



O benchmarking com o **Poli Quant** (vencedores do último Itaú Quant Challenge) já está em andamento para alinhar stack técnico, dinâmica de treinos e preparação específica. Membros do núcleo que participarem de challenges terão **prioridade de suporte** e poderão utilizar o conteúdo do núcleo diretamente nas entregas competitivas.

Além do Itaú Quant, o conteúdo do núcleo também prepara para:

- **Top Gestor** — módulo de Gestão de Risco e Otimização de Portfólio;
- **Hackathons de dados financeiros** — habilidades de ML e feature engineering;
- **Processos seletivos em buy-side e mesas quant** — domínio de Python, estatística e backtesting.

Considerações Finais

O Núcleo Quant nasce para dar à Liga uma **vantagem competitiva real**: membros preparados para challenges quantitativos, com processo claro, entregas padronizadas e stack técnico consistente. O cronograma de 12 semanas equilibra teoria e prática, e as entregas parciais garantem que o aprendizado é contínuo — não concentrado na véspera da competição.

A meta é simples: **quem passar pelo núcleo sai sabendo montar, testar e defender uma estratégia quantitativa do zero.**

Atenciosamente,

Arthur Pires Lopes
Diretor de Pesquisa — Núcleo Quant
Liga de Mercado Financeiro — UFU