Liga de Mercado Financeiro

ESTUDO GUIADO – S3

Estatística Aplicada ao Mercado Financeiro

Bloco	Sessão	Formato
Bloco 1 – Fundamentos	S3	Assíncrono (estudo individual)

Pré-requisito: S1 e S2 (Python, pandas, retornos simples e log-retornos)

Scripts desta aula:

Arquivo	Tópico	Caso prático
`s3_01_estatistica_descritiva.py`	Estatística Descritiva	PETR4, VALE3 e ITUB4 (2020–2024)
`s3_02_distribuicoes.py`	Distribuições	IBOVESPA, VaR por distribuição
`s3_03_testes_hipotese.py`	Testes de Hipótese	Retorno médio e autocorrelação
`s3_04_correlacao.py`	Correlação	Portfólio com 6 ativos

Como usar este material: leia cada seção e execute o script correspondente em paralelo. As caixas **Script Python** no início de cada seção indicam qual arquivo abrir. Instale as dependências com:

```
pip install yfinance pandas numpy scipy statsmodels matplotlib seaborn
```

Sumário

1 Estatística Descritiva **3**
1.1 Por que estatística descritiva em finanças? . . . 3
1.2 Medidas de Tendência Central . . . 3
1.3 Medidas de Dispersão . . . 4
1.4 Quartis, IQR e Detecção de Outliers . . . 4
1.5 Momentos Estatísticos: Assimetria e Curtose . . . 5
1.6 Percentis e o Value at Risk (VaR) . . . 6

2 Distribuições de Probabilidade **8**
2.1 Distribuição Normal: ponto de partida . . . 8
2.2 Distribuição t-Student: graus de liberdade e caudas pesadas . . . 8
2.3 O impacto prático: a cauda esquerda . . . 9
2.4 Impacto no VaR . . . 10
2.5 Tabela de referência: distribuições e seus usos . . . 11

3 Testes de Hipótese **12**
3.1 Framework Geral . . . 12
3.2 Erros de Decisão . . . 12
3.3 Teste t de Uma Amostra . . . 13
3.4 Teste de Ljung-Box: os retornos têm padrão no tempo? . . . 13

4 Correlação **15**
4.1 Correlação de Pearson . . . 15
4.2 Correlação de Spearman . . . 16
4.3 Correlação Rolante: a correlação muda ao longo do tempo . . . 16
4.4 Em crises, tudo cai junto . . . 16
4.5 Correlação e Diversificação de Portfólios . . . 17

5 Conexões com o Cronograma do Curso **19**

Referências **19**

Estatística Descritiva

Script Python: `s3_01_estatistica_descritiva.py`

Caso prático: análise descritiva completa dos retornos diários de PETR4, VALE3 e ITUB4 (2020–2024). Gera histogramas, boxplots e Q-Q plots comparativos. Execute este arquivo enquanto estuda esta seção.

Por que estatística descritiva em finanças?

Antes de qualquer modelo (VaR, backtest, ML) precisamos *entender* os dados. A estatística descritiva resume uma série de números em poucas medidas essenciais, respondendo a três perguntas fundamentais:

- **Onde está o centro?** Quanto o ativo retorna em média?
- **Quão dispersos são os valores?** Qual a volatilidade?
- **Que formato tem a distribuição?** Os retornos são simétricos? Há eventos extremos frequentes?

Respostas erradas aqui se propagam para todo o pipeline quantitativo. Um modelo de risco calibrado com a volatilidade errada subestima ou superestima reservas de capital, com consequências reais.

Medidas de Tendência Central

Tendência central é o valor em torno do qual os retornos se concentram.

Definição 1.1 (Média Aritmética)**.** Dado um conjunto de n retornos observados $r_1, r_2, \ldots, r_n$:

$$\bar{r} = \frac{1}{n} \sum_{i=1}^{n} r_i$$

onde r_i é o retorno do pregão i e n é o número total de observações. A média considera todos os valores com peso igual, o que a torna sensível a retornos extremos (crashes e rallies pontuais).

Definição 1.2 (Mediana)**.** A mediana m é o valor que divide a amostra ao meio: exatamente metade dos retornos fica abaixo dela e metade acima. Ao contrário da média, a mediana **não é afetada por valores extremos**, pois depende apenas da posição central dos dados, não de seus valores absolutos.

Em séries financeiras, compare sempre média e mediana:

- $\bar{r} < m$: perdas extremas são mais intensas que ganhos extremos (assimétrico à esquerda)
- $\bar{r} > m$: ganhos extremos dominam (assimétrico à direita)
- $\bar{r} \approx m$: distribuição aproximadamente simétrica

Definição 1.3 (Retorno Médio Anualizado)**.** O Brasil usa 252 dias úteis como convenção anual. Dado o retorno médio diário $\bar{r}_d$ calculado a partir de log-retornos:

$$\bar{r}_{\text{anual}} = \bar{r}_d \times 252$$

Para retornos simples (calculados com `pct_change()`), a anualização correta é geométrica, pois os retornos se compõem multiplicativamente ao longo do tempo:

$$\bar{r}^{\text{simples}}_{\text{anual}} = (1 + \bar{r}_d)^{252} - 1$$

Insight Financeiro

Para PETR4, a média dos retornos diários costuma ser menor que a mediana, confirmando a assimetria esquerda típica de ações de alta volatilidade. A maioria dos dias apresenta retorno ligeiramente positivo, mas os dias de queda extrema são mais intensos, puxando a média para baixo. Esse padrão é a regra, não a exceção, em ações brasileiras.

Medidas de Dispersão

Dispersão mede o quanto os retornos se afastam do valor central. Em finanças, dispersão é sinônimo de **risco**: quanto mais dispersos os retornos, mais incerto é o resultado futuro do investimento.

Definição 1.4 (Variância e Desvio-Padrão Amostral)**.** A **variância** mede a dispersão média ao quadrado em relação à média:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(r_i - \bar{r})^2$$

onde $r_i - \bar{r}$ é o desvio de cada retorno em relação à média, e $n-1$ (em vez de n) é a correção de Bessel, que torna s^2 um estimador não-enviesado da variância populacional σ^2.

O **desvio-padrão** $s = \sqrt{s^2}$ tem a mesma unidade dos retornos (por exemplo, % ao dia) e é a medida de risco mais usada na prática.

Definição 1.5 (Volatilidade Anualizada)**.** A **volatilidade** é o desvio-padrão dos retornos, medida de risco padrão da indústria. Para converter volatilidade diária em anual, usa-se a **regra da raiz-quadrada do tempo**, válida quando os retornos de dias diferentes são independentes entre si:

$$\sigma_{\text{anual}} = \sigma_{\text{diária}} \times \sqrt{252}$$

Por exemplo, uma volatilidade diária $\sigma_{\text{diária}} = 1{,}5\%$ implica volatilidade anual $\sigma_{\text{anual}} = 1{,}5\% \times \sqrt{252} \approx 23{,}8\%$.

Atenção

A regra $\times\sqrt{252}$ pressupõe que os retornos de dias diferentes são independentes. Quando há **agrupamento de volatilidade** (dias voláteis tendem a ser seguidos por dias igualmente voláteis), essa regra subestima o risco de longo prazo. Esse fenômeno é modelado pelos processos GARCH, vistos na S4.

Definição 1.6 (Coeficiente de Variação (CV))**.** O CV normaliza o risco pelo retorno, permitindo comparar ativos em escalas diferentes:

$$CV = \frac{\sigma}{|\bar{r}|}$$

onde σ é o desvio-padrão e $|\bar{r}|$ é o valor absoluto da média. Um CV menor indica que o ativo entrega mais retorno por unidade de risco assumido.

Quartis, IQR e Detecção de Outliers

Quartis são pontos que dividem os dados ordenados em quatro partes iguais, cada uma contendo 25% das observações. Imagine todos os retornos do período organizados do menor ao maior; os quartis marcam as posições 25%, 50% e 75% desse ordenamento:

Definição 1.7 (Quartis)**.** ▶ Q_1 (primeiro quartil): 25% dos retornos ficam abaixo deste valor. É o percentil 25

- Q_2 (segundo quartil): a mediana. Exatamente metade dos retornos fica abaixo. É o percentil 50
- Q_3 (terceiro quartil): 75% dos retornos ficam abaixo deste valor. É o percentil 75

A **Amplitude Interquartil (IQR)** é a distância entre o terceiro e o primeiro quartil:

$$\text{IQR} = Q_3 - Q_1$$

O IQR representa a faixa central de 50% dos retornos (do 25º ao 75º percentil), ignorando os extremos de ambos os lados. Por isso é uma medida de dispersão **robusta**: crashes e rallies pontuais não a afetam.

O critério de Tukey usa o IQR para identificar automaticamente retornos atípicos. Uma observação é sinalizada como outlier se estiver fora do intervalo:

$$\left[Q_1 - 1{,}5 \cdot \text{IQR},\ \ Q_3 + 1{,}5 \cdot \text{IQR}\right]$$

O boxplot visualiza exatamente essa estrutura: a caixa central abrange Q_1 a Q_3, a linha interna é a mediana, e os pontos além dos limites são os outliers.

Momentos Estatísticos: Assimetria e Curtose

Média e desvio-padrão descrevem o centro e a dispersão, mas não dizem como os retornos se distribuem em torno desse centro. Para isso, usamos dois **momentos** adicionais.

O que é um momento estatístico? É uma medida que resume uma característica específica da forma de uma distribuição. A ideia vem da física: assim como o momento de uma força captura sua intensidade e direção, cada momento estatístico captura um aspecto diferente da distribuição. Calculamos os momentos elevando os desvios em relação à média a potências sucessivas:

- **1° momento** (média $\bar{r}$): descreve o *centro* da distribuição. $\sum(r_i)/n$ – os desvios elevados à 1ª potência
- **2° momento central** (variância s^2): descreve a *dispersão*. $\sum(r_i - \bar{r})^2/n$ – os desvios elevados ao quadrado, sempre positivos
- **3° momento padronizado** (assimetria g_1): descreve a *direção* em que a distribuição inclina. O cubo preserva o sinal ($+$ ou $-$) do desvio, indicando se a cauda longa está à esquerda ou à direita
- **4° momento padronizado** (curtose g_2): descreve o *peso das caudas*. A quarta potência amplifica desvios extremos muito mais do que desvios pequenos, capturando se os extremos são frequentes

Definição 1.8 (Assimetria (Skewness, g_1))**.** A assimetria mede se a distribuição tem uma cauda mais longa de um lado. É o terceiro momento padronizado:

$$g_1 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{r_i - \bar{r}}{s}\right)^3$$

onde $r_i - \bar{r}$ é o desvio de cada retorno em relação à média e s é o desvio-padrão. A divisão por s torna a medida adimensional (sem unidade), comparável entre ativos diferentes. O expoente 3 preserva o sinal:

- $g_1 = 0$: distribuição simétrica (caso da Normal)
- $g_1 < 0$: cauda esquerda mais longa; perdas extremas ocorrem com mais frequência ou magnitude do que ganhos extremos (*negatively skewed*)

- $g_1 > 0$: cauda direita mais longa; ganhos extremos dominam (*positively skewed*)

Definição 1.9 (Curtose e Curtose em Excesso (g_2, κ))**.** A curtose mede o peso das caudas em relação à Normal. É o quarto momento padronizado:

$$g_2 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{r_i - \bar{r}}{s}\right)^4 \qquad \text{(curtose total)}$$

O expoente 4 sempre resulta em valores positivos e amplifica desvios grandes, tornando g_2 sensível a eventos extremos. A distribuição Normal tem curtose total $g_2 = 3$. Subtrai-se 3 para obter a **curtose em excesso** κ, que mede o excesso de peso nas caudas em relação à Normal:

$$\kappa = g_2 - 3$$

- $\kappa = 0$: caudas iguais à Normal (*mesocúrtica*)
- $\kappa > 0$: distribuição **leptocúrtica**; caudas mais pesadas, eventos extremos mais frequentes do que a Normal prevê
- $\kappa < 0$: distribuição **platicúrtica**; caudas mais leves, retornos concentrados próximos à média

Insight Financeiro

Ações do IBOVESPA tipicamente têm $g_1 < 0$ e $\kappa > 0$, combinação chamada de **distribuição leptocúrtica assimétrica à esquerda**. A implicação para gestão de risco é severa: modelos que assumem normalidade subestimam a probabilidade de perdas extremas. Em 16 de março de 2020, o IBOVESPA caiu $-12{,}17\%$ em um único pregão. Com $\sigma = 2\%$/dia, isso representa um evento de $-6{,}1\sigma$, ao qual a distribuição Normal atribuiria probabilidade de $\approx 5{,}8 \times 10^{-10}$ (menos de 1 em 1 bilhão de pregões). Na prática, eventos assim ocorrem a cada poucos anos.

Percentis e o Value at Risk (VaR)

Os **percentis** generalizam os quartis: onde os quartis dividem os dados em 4 partes, os percentis permitem dividir em qualquer proporção. São especialmente importantes em finanças porque os percentis inferiores correspondem às perdas extremas que definem o risco.

Definição 1.10 (Percentil)**.** O percentil P_α é o valor abaixo do qual se encontra exatamente $\alpha\%$ das observações. Para calculá-lo formalmente, precisamos da função de distribuição acumulada (CDF), que para qualquer valor x indica quantos por cento dos retornos são menores que x:

$$F(x) = P(R \leq x) \qquad \text{(proporção de retornos menores que } x\text{)}$$

O percentil P_α é o inverso dessa função: dado que queremos a proporção $\alpha/100$, qual é o valor x correspondente?

$$P_\alpha = F^{-1}\left(\frac{\alpha}{100}\right)$$

Exemplo prático: $P_5 = F^{-1}(0{,}05)$ é o retorno abaixo do qual ficam os piores 5% dos dias. Se $P_5 = -2{,}8\%$, significa que em 5% dos pregões o ativo perdeu mais de 2,8% em um único dia.

No contexto de risco, os percentis inferiores recebem o nome de **Value at Risk**:

- $P_5 \Rightarrow$ **VaR 95%**: perda que é excedida em apenas 5% dos dias
- $P_1 \Rightarrow$ **VaR 99%**: perda que é excedida em apenas 1% dos dias

O VaR responde à pergunta: *"qual é a pior perda esperada em condições normais de mercado?"* Estudaremos o VaR em profundidade na S5.

Resumo do Tópico

Tópico 1 – Estatística Descritiva

- **Média** é o retorno esperado; **mediana** é o valor central robusto a extremos. Comparar as duas revela a assimetria
- **Desvio-padrão** = risco; $\sigma_{\text{anual}} = \sigma_{\text{diário}} \times \sqrt{252}$, regra padrão da indústria
- **Quartis** dividem a amostra ordenada em 4 partes iguais; **IQR** $= Q_3 - Q_1$ mede a dispersão central de 50% dos dados sem ser afetado por extremos
- **Momentos estatísticos:** 1º = média (centro), 2º = variância (dispersão), 3º = assimetria (direção da cauda longa), 4º = curtose (peso das caudas)
- **Assimetria** $g_1 < 0$: ações brasileiras tipicamente têm cauda esquerda mais pesada
- **Curtose em excesso** $\kappa > 0$: eventos extremos mais frequentes do que a Normal prevê
- **Percentil** P_α = VaR histórico: base do gerenciamento de risco (S5)
- Script: `s3_01_estatistica_descritiva.py`

Distribuições de Probabilidade

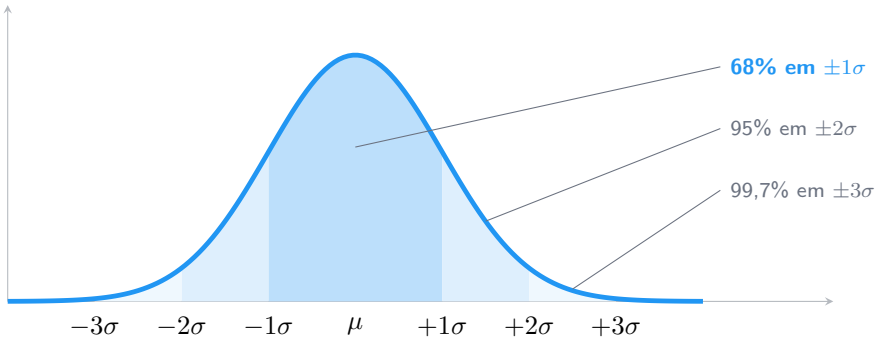
Script Python: `s3_02_distribuicoes.py`

Caso prático: ajuste de distribuições (Normal, t-Student) aos retornos diários do IBOVESPA, comparação visual das caudas e impacto no VaR. Execute enquanto estuda esta seção.

A pergunta central é: **qual distribuição descreve melhor os retornos diários de ações?** A resposta tem impacto direto em como calculamos risco e alocamos capital.

Distribuição Normal: ponto de partida

A distribuição Normal é simétrica em torno da média e tem caudas que decaem muito rapidamente. O gráfico abaixo mostra sua forma e a célebre **regra 68-95-99,7**:



Regra 68-95-99,7: na Normal, 68% dos retornos ficam dentro de $\pm 1\sigma$, 95% dentro de $\pm 2\sigma$ e 99,7% dentro de $\pm 3\sigma$. Isso significa que retornos além de 3σ deveriam ocorrer em apenas 0,3% dos dias, ou seja, menos de 1 vez por ano. Com ações brasileiras, ocorrem muito mais.

Distribuição t-Student: graus de liberdade e caudas pesadas

A distribuição t-Student é parecida com a Normal, mas com caudas mais pesadas. Ela tem um parâmetro extra, os **graus de liberdade** (ν), que controla exatamente o quão pesadas são essas caudas.

O que são graus de liberdade? Imagine que você tem ν observações independentes. Ao estimar a média, você "gasta" uma delas, restando $\nu - 1$ informações livres para medir a variabilidade. Quanto menos observações livres (ν pequeno), mais incerteza existe sobre a forma da distribuição, e as caudas precisam ser mais pesadas para acomodar essa incerteza. À medida que $\nu \to \infty$ (informação infinita), a t-Student converge para a Normal.

Definição 2.1 (Graus de liberdade e curtose na t-Student)**.** Para a distribuição t com ν graus de liberdade, a curtose em excesso é:

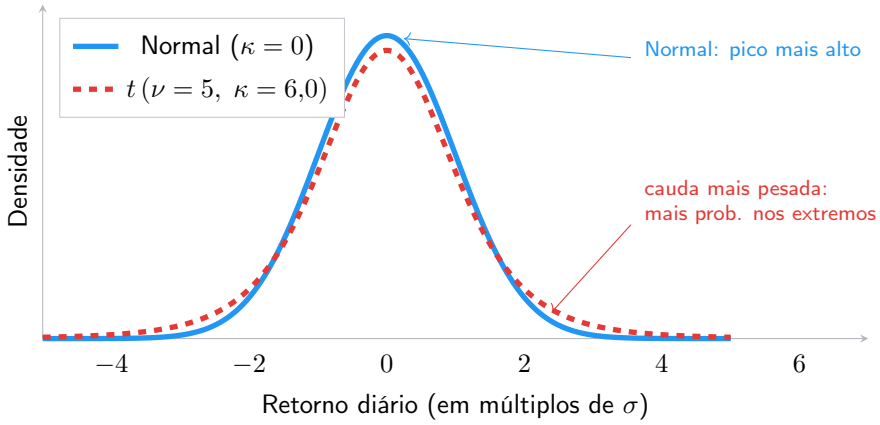
$$\kappa = \frac{6}{\nu - 4} \qquad \text{(válido apenas para } \nu > 4\text{)}$$

onde $\nu > 0$ é o número de graus de liberdade. Para $\nu \leq 4$, a curtose é formalmente infinita.

Interpretação direta: quanto menor ν, maior κ, mais pesadas as caudas:

- $\nu = 30$: $\kappa = 0{,}24$ — quase igual à Normal ($\kappa = 0$)
- $\nu = 10$: $\kappa = 1{,}0$ — caudas moderadamente mais pesadas
- $\nu = 5$: $\kappa = 6{,}0$ — caudas muito mais pesadas
- $\nu = 4$: $\kappa = \infty$ — curtose matematicamente infinita
- $\nu = 3$: $\kappa = \infty$ — curtose matematicamente infinita

O gráfico abaixo compara a Normal com a t-Student para $\nu = 5$, típico de ações. O ponto crucial está nas extremidades: a t-Student é *mais baixa* no centro e *mais alta* nas caudas em comparação com a Normal.

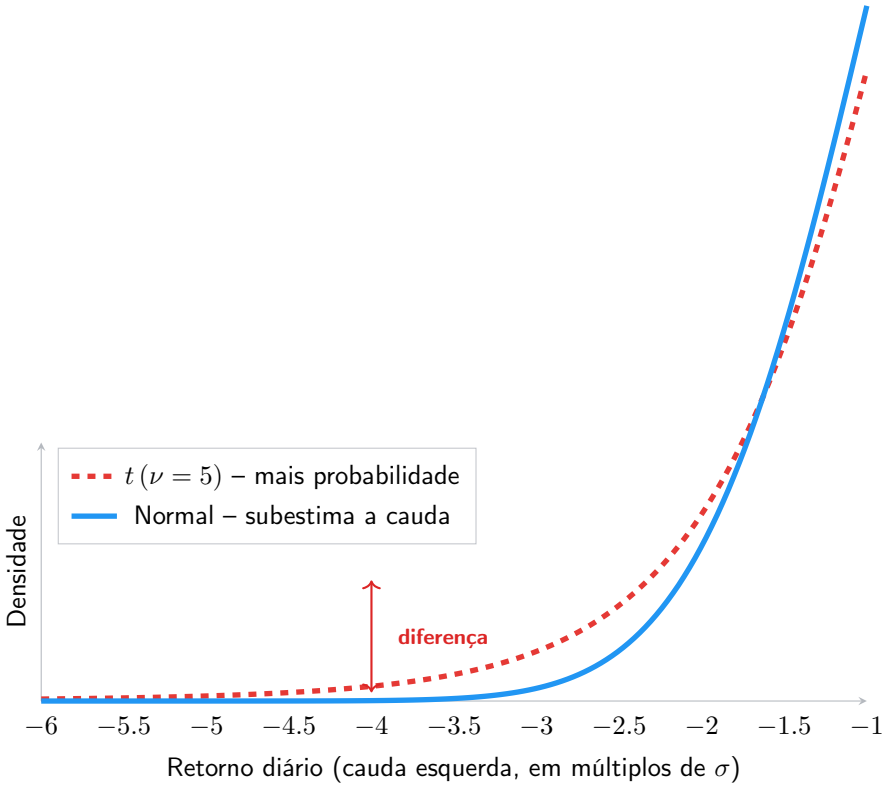


Insight Financeiro

Estimativas empíricas para o IBOVESPA apontam $\nu \approx 4$ a 5. Com $\nu = 5$, a curtose em excesso é $\kappa = 6$, ou seja, o peso das caudas é 6 vezes maior do que a Normal prevê. Um retorno de -5σ é centenas de vezes mais provável sob a t-Student do que sob a Normal. Por isso, modelos profissionais de estimação de risco em bancos e fundos preferem a t-Student à Normal.

O impacto prático: a cauda esquerda

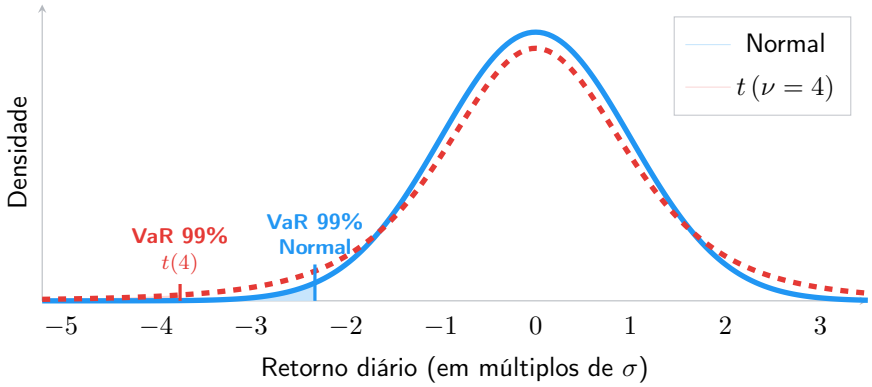
A cauda esquerda da distribuição de retornos representa as perdas extremas. O gráfico abaixo isola essa região e mostra que a Normal prevê quase zero probabilidade onde os dados realmente acontecem:



A mensagem é direta: na cauda esquerda (perdas extremas), a t-Student atribui uma probabilidade muito maior do que a Normal. Usar a Normal para estimar risco significa sistematicamente subestimar a chance de perdas severas.

Impacto no VaR

O **VaR** (Value at Risk) é o quantil da distribuição de retornos: a perda que não será excedida com determinada probabilidade. A escolha da distribuição muda diretamente o capital alocado para cobrir riscos.



Exemplo numérico com carteira de R$ 100.000 e $\sigma = 1{,}5\%$/dia:

O quantil 1% da Normal padrão é $z_{0,01} = -2{,}326$; o da t com $\nu = 4$ é $t_{0,01;\,4} = -3{,}747$ (obtido por tabela ou `scipy.stats.t.ppf(0.01, df=4)`).

- VaR 99% pela Normal: $2{,}326 \times \text{R\$}\,1.500 = \text{R\$}\,3.489$
- VaR 99% pela $t(4)$: $3{,}747 \times \text{R\$}\,1.500 = \text{R\$}\,5.621$

Diferença de R$ 2.132 por posição, causada unicamente pela escolha da distribuição. Em um fundo com R$ 500 milhões, isso representa mais de R$ 7 milhões a menos em capital reservado pelo modelo que usa a Normal.

Tabela de referência: distribuições e seus usos

Distribuição	Curtose	Caudas	Uso típico em finanças
Normal	$\kappa = 0$	Leves	Referência, modelo de Black-Scholes
$t(\nu = 30)$	$\kappa = 0{,}23$	Quase Normal	Ativos com baixa volatilidade
$t(\nu = 10)$	$\kappa = 1{,}0$	Moderadas	VaR conservador
$t(\nu = 5)$	$\kappa = 6{,}0$	Pesadas	VaR em bancos e gestoras
$t(\nu \leq 4)$	$\kappa = \infty$	Muito pesadas	Ativos de alta volatilidade

Resumo do Tópico

Tópico 2 – Distribuições

- A Normal subestima eventos extremos; a t-Student captura melhor as caudas
- **Graus de liberdade** ν: controlam o peso das caudas. Menor $\nu \Rightarrow$ caudas mais pesadas. Quando $\nu \to \infty$, a t-Student vira Normal
- A curtose da t-Student é $\kappa = 6/(\nu - 4)$ para $\nu > 4$; para $\nu \leq 4$, é infinita
- Para o IBOVESPA, estimativas empíricas apontam $\nu \approx 4$ a 5
- Usar Normal em vez de t-Student pode subestimar o VaR em 50% ou mais
- Script: `s3_02_distribuicoes.py`

Testes de Hipótese

Script Python: `s3_03_testes_hipotese.py`

Caso prático: (A) teste se o retorno médio do IBOVESPA é diferente de zero; (B) teste de autocorrelação dos retornos com Ljung-Box. Execute enquanto estuda esta seção.

Framework Geral

Um **teste de hipótese** é um procedimento formal para decidir, com base em dados, se uma afirmação sobre o mercado é sustentada ou não. O raciocínio é sempre o mesmo: *assumo que não acontece nada de especial* (hipótese nula) e verifico se os dados observados são improváveis demais para essa suposição.

Todo teste segue cinco passos:

1. **Formular as hipóteses**
   - H_0 (hipótese nula): a afirmação que queremos testar, formulada como "nenhum efeito". Exemplo: *"o retorno médio da estratégia é zero"*
   - H_1 (hipótese alternativa): o que concluímos se H_0 for rejeitada. Exemplo: *"o retorno médio é diferente de zero"*
2. **Calcular a estatística de teste** a partir dos dados. É um número que resume o quanto os dados se afastam do que H_0 prevê
3. **Fixar o nível de significância** α: a probabilidade máxima que aceitamos de rejeitar H_0 quando ela é verdadeira (falso alarme). Convenção: $\alpha = 0{,}05$ (5%)
4. **Calcular o p-valor**: a probabilidade de observar uma estatística tão extrema quanto a calculada *supondo que H_0 é verdadeira*. Um p-valor pequeno significa que os dados são muito improváveis sob H_0
5. **Decidir**: se $p < \alpha$, rejeitar H_0; caso contrário, não há evidência suficiente para rejeitar

Atenção

O que o p-valor NÃO é: o p-valor não é a probabilidade de H_0 ser verdadeira. É a probabilidade dos *dados*, assumindo que H_0 é verdadeira. Além disso, significância estatística ($p < 0{,}05$) não implica significância econômica: uma estratégia pode ter retorno médio estatisticamente diferente de zero, mas economicamente irrelevante após custos de transação.

Erros de Decisão

Todo teste pode cometer dois tipos de erro:

	H_0 é verdadeira	H_0 é falsa
Não rejeitar H_0	Correto $(1-\alpha)$	**Erro Tipo II** (β)
Rejeitar H_0	**Erro Tipo I** (α)	Correto: Poder $= 1-\beta$

O **poder do teste** $= 1 - \beta$ é a probabilidade de detectar um efeito real quando ele existe. O poder aumenta com o tamanho da amostra n: com mais dados, conseguimos detectar efeitos cada vez menores.

Teste t de Uma Amostra

Problema: queremos saber se o retorno médio de um ativo é diferente de zero. Isso equivale a perguntar se há evidência estatística de que o mercado gera retorno esperado positivo ou negativo.

Definição 3.1 (Estatística t de uma amostra)**.** Para testar se a média populacional μ é igual a um valor de referência μ_0:

$$H_0 : \mu = \mu_0 \qquad \text{contra} \qquad H_1 : \mu \neq \mu_0$$

Calcula-se a estatística t, que mede quantos erros-padrão a média amostral $\bar{r}$ está afastada de μ_0:

$$t = \frac{\bar{r} - \mu_0}{s/\sqrt{n}}$$

onde:

- $\bar{r}$: média amostral dos retornos
- μ_0: valor de referência (geralmente $\mu_0 = 0$, "sem retorno")
- s: desvio-padrão amostral dos retornos
- n: número de observações
- $s/\sqrt{n}$: erro-padrão da média (incerteza sobre $\bar{r}$ dada a amostra)

Sob H_0, a estatística t segue uma distribuição t com $n - 1$ graus de liberdade. Valores grandes de $|t|$ indicam que $\bar{r}$ está longe de μ_0, sugerindo que H_0 é improvável. O p-valor mede exatamente essa probabilidade.

Exemplo 3.1 (IBOVESPA 2010–2024)**.** Com $n = 3.520$ pregões, média diária $\bar{r} = 0{,}03\%$ e desvio-padrão $s = 1{,}5\%$, testamos $H_0 : \mu = 0$:

$$t = \frac{0{,}03\%}{1{,}5\%/\sqrt{3520}} = \frac{0{,}0003}{0{,}000253} \approx 1{,}18$$

Para $\alpha = 0{,}05$ (bicaudal), o valor crítico é $t_{0{,}025;\,3519} \approx 1{,}96$. Como $|1{,}18| < 1{,}96$, o p-valor é $\approx 0{,}24$, e **não rejeitamos** H_0.

Interpretação: com os dados disponíveis, não há evidência estatística suficiente de que o IBOVESPA gera retorno médio diferente de zero. Isso é consistente com a Hipótese dos Mercados Eficientes (HME) na forma fraca.

Teste de Ljung-Box: os retornos têm padrão no tempo?

Problema: se os retornos de hoje dependem dos retornos de dias anteriores (autocorrelação), o mercado tem memória e padrões exploráveis. O teste de Ljung-Box verifica se essa dependência existe.

Autocorrelação $\hat{\rho}_k$ mede a correlação entre o retorno de hoje r_t e o retorno de k dias atrás r_{t-k}. Se $\hat{\rho}_k \approx 0$ para todos os lags k, os retornos são independentes no tempo (sem memória).

Definição 3.2 (Estatística de Ljung-Box Q_m)**.** Para testar se os retornos são independentes nos lags 1 até m:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_m = 0 \qquad \text{(sem autocorrelação até o lag } m\text{)}$$

A estatística resume as autocorrelações amostrais $\hat{\rho}_1, \hat{\rho}_2, \ldots, \hat{\rho}_m$:

$$Q_m = n(n+2) \sum_{k=1}^{m} \frac{\hat{\rho}_k^2}{n-k}$$

onde:

- n: número de observações na série
- m: número de lags testados (escolha típica: $m = 5$, 10 ou 20)
- $\hat{\rho}_k$: autocorrelação amostral no lag k
- $n+2$ e $n-k$: fatores de correção para amostras finitas

Sob H_0, $Q_m \sim \chi^2(m)$. Um p-valor baixo indica autocorrelação significativa.

Propriedade 3.1 (Dois usos do Ljung-Box em finanças)**.** O teste é aplicado a duas séries diferentes, com interpretações opostas:

- **Aplicado a r_t (retornos)**: testa se há padrão de direção previsível. Em mercados eficientes, esperamos *não rejeitar* H_0: retornos passados não preveem retornos futuros
- **Aplicado a r_t^2 (retornos ao quadrado)**: testa se há padrão de *volatilidade*. Quase sempre *rejeitamos* H_0, pois períodos voláteis tendem a ser seguidos por períodos voláteis (agrupamento de volatilidade). Esse resultado é o diagnóstico padrão antes de estimar um modelo GARCH (S4)

Insight Financeiro

No IBOVESPA: Ljung-Box aplicado a r_t tipicamente não rejeita H_0 (retornos sem padrão linear), mas aplicado a r_t^2 rejeita com alta confiança (volatilidade autocorrelacionada). Essa combinação é evidência de que o mercado é eficiente na direção, mas não na magnitude do risco, motivando diretamente o uso de modelos GARCH.

Resumo do Tópico

Tópico 3 – Testes de Hipótese

- H_0 é a hipótese nula ("sem efeito"); H_1 é o que concluímos quando H_0 é rejeitada
- p-valor: probabilidade dos dados observados assumindo H_0 verdadeira. Se $p < \alpha$, rejeitar H_0
- **Erro Tipo I** (α): rejeitar H_0 quando é verdadeira. **Erro Tipo II** (β): não rejeitar quando é falsa
- **Teste** t: mede quantos erros-padrão $\bar{r}$ está de μ_0. Retorno médio do IBOV não é estatisticamente diferente de zero (HME)
- **Ljung-Box em** r_t: testa autocorrelação de direção (raramente rejeitada em ações)
- **Ljung-Box em** r_t^2: testa agrupamento de volatilidade (quase sempre rejeitada, motiva GARCH)
- Script: `s3_03_testes_hipotese.py`

Correlação

Script Python: `s3_04_correlacao.py`

Caso prático: análise completa de correlação entre PETR4, VALE3, ITUB4, WEGE3, MGLU3 e BBAS3, incluindo correlação rolante e implicações para diversificação. Execute enquanto estuda esta seção.

Correlação mede o grau em que dois ativos se movem juntos. É a ferramenta central para construir portfólios diversificados: combinar ativos com baixa correlação reduz o risco do conjunto sem sacrificar retorno esperado.

Correlação de Pearson

Intuição: imagine os retornos diários de PETR4 e VALE3. Se sempre que a PETR4 sobe a VALE3 também sobe, a correlação é próxima de $+1$. Se sempre fazem o oposto, é próxima de -1. Se não há relação, é próxima de 0.

Definição 4.1 (Coeficiente de Correlação de Pearson (ρ))**.** Dados os retornos diários de dois ativos X e Y, com médias $\bar{x}$ e $\bar{y}$:

$$\rho(X,Y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

onde:

- x_i e y_i: retornos dos ativos X e Y no pregão i
- $\bar{x}$, $\bar{y}$: médias dos retornos de cada ativo
- $(x_i - \bar{x})(y_i - \bar{y})$: produto dos desvios; positivo quando ambos sobem ou ambos caem juntos, negativo quando se opõem
- O denominador normaliza o resultado para a faixa $[-1, +1]$

Propriedades essenciais:

- $-1 \leq \rho \leq 1$ sempre
- $\rho = +1$: os dois ativos se movem perfeitamente juntos (nenhuma diversificação)
- $\rho = 0$: nenhuma relação *linear* entre os ativos
- $\rho = -1$: os ativos se movem perfeitamente em sentidos opostos (hedge perfeito)
- Atenção: $\rho = 0$ não implica independência; mede apenas dependência **linear**

Definição 4.2 (Significância estatística da correlação)**.** Para testar se a correlação observada r é significativamente diferente de zero ($H_0 : \rho = 0$ vs. $H_1 : \rho \neq 0$), calcula-se:

$$t = r\sqrt{\frac{n-2}{1-r^2}} \;\sim\; t(n-2) \quad \text{sob } H_0$$

onde n é o número de pregões. Correlações visualmente pequenas podem ser estatisticamente significativas com amostras grandes.

Correlação de Spearman

A correlação de Pearson mede dependência *linear*. Quando os retornos têm caudas pesadas (o que é usual em ações), outliers podem distorcer esse resultado. A correlação de Spearman resolve isso trabalhando com os **ranks** dos dados em vez dos valores originais.

Definição 4.3 (Correlação de Spearman (ρ_S))**.** Ordenam-se as observações de cada ativo do menor para o maior e atribui-se a cada uma sua posição (rank). Por exemplo, o menor retorno recebe rank 1, o maior recebe rank n. A correlação de Spearman é a correlação de Pearson calculada sobre esses ranks:

$$\rho_S = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)}$$

onde $d_i = \text{rank}(x_i) - \text{rank}(y_i)$ é a diferença entre os ranks do ativo X e do ativo Y no pregão i.

Vantagens sobre Pearson:

- Robusta a outliers: um retorno extremo muda o rank, mas não domina o cálculo
- Captura dependência **monotônica**: se Y sempre sobe quando X sobe (mesmo que não linearmente), Spearman detecta; Pearson pode não detectar
- Preferível quando os retornos têm distribuições assimétricas ou caudas pesadas

Correlação Rolante: a correlação muda ao longo do tempo

Uma correlação calculada sobre toda a amostra é uma média estática que esconde mudanças importantes. A **correlação rolante** recalcula a correlação em janelas móveis, revelando como a relação entre ativos evolui no tempo:

$$\hat{\rho}_t(w) = \text{Pearson dos retornos entre os pregões } (t-w+1) \text{ e } t$$

onde w é o tamanho da janela (tipicamente $w = 63$ dias úteis ≈ 3 meses).

Insight Financeiro

Em janelas de 63 dias, a correlação entre ITUB4 (Itaú) e BBAS3 (Banco do Brasil) varia historicamente de $\approx 0{,}40$ a $\approx 0{,}90$. Usar a correlação histórica estática para construir um portfólio ignora essa variação e pode levar a alocações inadequadas. Sempre visualize a correlação rolante antes de tomar decisões de portfólio.

Em crises, tudo cai junto

Um fenômeno bem documentado: durante períodos de estresse de mercado, as correlações entre ativos sobem significativamente. Ativos que pareciam diversificados em condições normais passam a se mover juntos justamente quando a diversificação seria mais necessária.

Isso significa que a diversificação funciona bem no dia a dia, mas tende a falhar em crises. Para proteger o portfólio em cenários extremos, é preciso incluir ativos com correlação estruturalmente negativa com ações em crises, como câmbio (dólar), títulos do governo de países desenvolvidos ou opções de proteção (puts).

Correlação e Diversificação de Portfólios

A correlação entre ativos determina diretamente o quanto a volatilidade do portfólio cai quando combinamos ativos. Antes da fórmula, entenda os três casos referência:

- $\bar{\rho} = 0$ **(ativos independentes):** quando um ativo cai, os outros não reagem. As perdas de uns são compensadas pelos ganhos de outros, e a volatilidade cai proporcionalmente a $1/\sqrt{n}$. Com 4 ativos independentes, a volatilidade cai pela metade: $\sigma/\sqrt{4} = \sigma \times 0{,}5$
- $\bar{\rho} = 1$ **(correlação perfeita positiva):** todos os ativos caem e sobem juntos, como se fossem o mesmo ativo. Adicionar mais ativos não reduz nenhum risco: $\sigma_{\text{port}} = \sigma$ independentemente de n
- $\bar{\rho} = -1$ **(correlação perfeita negativa):** quando um ativo cai, outro sobe na mesma proporção. Para $n = 2$ ativos, é possível zerar o risco completamente: $\sigma_{\text{port}} = 0$. Na prática, $\bar{\rho} = -1$ em todos os pares é matematicamente impossível para $n > 2$; ativos com ρ negativo ajudam, mas não eliminam o risco por completo

Na prática, $0 < \bar{\rho} < 1$ para a maioria das carteiras de ações do mesmo mercado, e a fórmula abaixo quantifica exatamente o benefício da diversificação nesse caso:

$$\underbrace{\sigma_{\text{portfólio}}}_{\text{volatilidade do portfólio}} = \underbrace{\sigma}_{\text{vol. de cada ativo}} \times \sqrt{\underbrace{\frac{1}{n}}_{\substack{\text{risco próprio} \\ \text{(se dilui com } n\text{)}}} + \underbrace{\bar{\rho}\left(1 - \frac{1}{n}\right)}_{\substack{\text{risco compartilhado} \\ \text{(não desaparece)}}}} \tag{1}$$

O que significa cada variável:

- $\sigma_{\text{portfólio}}$: a **volatilidade diária do portfólio como um todo**, ou seja, o desvio-padrão dos retornos da carteira inteira. É isso que queremos reduzir com a diversificação
- σ (sem subscrito): a **volatilidade diária de cada ativo individual** do portfólio. A fórmula assume que todos os n ativos têm a mesma volatilidade, simplificação útil para entender a estrutura do problema
- n: o **número de ativos** no portfólio, todos com o mesmo peso $1/n$. Quanto maior n, mais diluído fica o risco próprio de cada empresa
- $\bar{\rho}$ (rho com barra): a **correlação média entre todos os pares de ativos** do portfólio. Se há 3 ativos (A, B, C), $\bar{\rho}$ é a média das correlações ρ_{AB}, ρ_{AC} e ρ_{BC}. É o parâmetro mais importante: ele define o piso mínimo da volatilidade do portfólio

Por que existe um piso? A parcela $\bar{\rho}(1 - 1/n)$ representa o risco que todos os ativos *compartilham* (o mercado como um todo caindo, por exemplo). Quando $n \to \infty$, essa parcela converge para $\bar{\rho}$, e a volatilidade do portfólio converge para $\sigma\sqrt{\bar{\rho}}$. Por mais ativos que você adicione ao portfólio, esse risco sistemático não desaparece.

Exemplo 4.1 (Quanto a diversificação reduz o risco? $\sigma = 2\%$/dia, $\bar{\rho} = 0{,}40$)**.** Com cada ativo tendo volatilidade diária de 2% e correlação média de $0{,}40$, aplicamos a fórmula para diferentes tamanhos de portfólio:

n ativos	Conta	σ_{port}	Redução vs. 1 ativo
1	$2\sqrt{1{,}00}$	$2{,}00\%$	—
5	$2\sqrt{0{,}20 + 0{,}4 \times 0{,}80} = 2\sqrt{0{,}52}$	$1{,}44\%$	-28%
20	$2\sqrt{0{,}05 + 0{,}4 \times 0{,}95} = 2\sqrt{0{,}43}$	$1{,}31\%$	-35%
∞	$2\sqrt{0{,}40}$	$1{,}26\%$	-37% **(piso)**

Leitura da tabela: o ganho de diversificação é decrescente. De 1 para 5 ativos, a volatilidade cai $0{,}56$ p.p. De 5 para 20 ativos, cai apenas mais $0{,}13$ p.p. A partir de 15–20 ativos, o benefício marginal de adicionar mais um ativo é praticamente zero, pois o risco sistemático (os 37% restantes) não pode ser eliminado diversificando dentro do mesmo mercado.

Para romper o piso de $1{,}26\%$, seria preciso reduzir $\bar{\rho}$ abaixo de $0{,}40$, o que exige incluir ativos de **classes distintas**: dólar (que historicamente se aprecia em crises brasileiras), ouro, títulos de países desenvolvidos ou fundos com estratégias descorrelacionadas de ações.

Resumo do Tópico

Tópico 4 – Correlação

- **Pearson** mede dependência linear entre retornos. Varia de -1 a $+1$. Sensível a outliers
- **Spearman** trabalha com ranks em vez de valores, sendo robusto a outliers e a distribuições com caudas pesadas
- **Correlação rolante** revela como a relação entre ativos muda com o tempo; sempre calcule antes de construir portfólios
- Em crises, correlações sobem: a diversificação falha exatamente quando mais importa
- A equação (1) mostra que $\bar{\rho}$ define o piso da volatilidade do portfólio, independentemente do número de ativos
- Para reduzir risco além desse piso, é preciso incluir ativos com $\bar{\rho}$ menor (câmbio, outros mercados)
- Script: `s3_04_correlacao.py`

Conexões com o Cronograma do Curso

Os conceitos desta aula formam a base para todo o restante do curso:

Sessão	Tópico	Usa da S3
S4	Séries Temporais	Ljung-Box, ACF, agrupamento de volatilidade, GARCH
S5	Gestão de Risco I	VaR histórico e paramétrico, distribuições, caudas pesadas
S6	Gestão de Risco II	Correlação, matriz de covariância, otimização de Markowitz
S7	Backtesting I	Teste de hipótese sobre retornos de estratégias
S8	Backtesting II	Poder estatístico, significância de métricas de desempenho
S9–S10	Machine Learning	Assimetria e curtose como features, retornos normalizados

Referências

- McNeil, A. J., Frey, R., & Embrechts, P. (2015). *Quantitative Risk Management: Concepts, Techniques and Tools*. Princeton University Press.
- Hull, J. C. (2022). *Options, Futures, and Other Derivatives*. Pearson.
- Fama, E. F., & French, K. R. (1992). The Cross-Section of Expected Stock Returns. *Journal of Finance*, 47(2), 427–465.
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Ljung, G. M., & Box, G. E. P. (1978). On a Measure of Lack of Fit in Time Series Models. *Biometrika*, 65(2), 297–303.
- Scipy Reference Guide. `https://docs.scipy.org/doc/scipy/`
- Statsmodels Documentation. `https://www.statsmodels.org/`