ACF/PACF

▼ 1. O que é?

ACF (Autocorrelation Function): mede a correlação entre a série e seus próprios valores passados (lags). Ou seja, verifica se o comportamento passado influencia o presente, considerando efeitos diretos e indiretos.
PACF (Partial Autocorrelation Function): mede a correlação direta entre a série e um lag específico, removendo o efeito dos lags intermediários.

ACF → visão geral da dependência
PACF → visão "limpa", isolando quem realmente influencia

ACF detecta dependência | PACF identifica a dependência direta

▼ 2. Para que serve?

- Verificar se a série possui **memória (dependência temporal)**

Dependência = O passado influencia o presente?

- Identificar **estrutura estatística** nos dados
- Diferenciar comportamento **"aleatório" vs estruturado**
- Servir como base para escolha de modelos como ARIMA (modela a média) e GARCH (modela a volatilidade)

Eles não geram previsão diretamente, eles ajudam você a **entender como a série se comporta** antes de modelar.

▼ 3. Quando usar ?

▼ 1. Verificar se existe dependência

Dependência = O passado influencia o presente?

O que você faz:

- Aplica ACF nos **retornos**

O que você está tentando responder:

> O passado ajuda a explicar o presente ou é tudo “aleatório”?

Como interpretar:

- Se praticamente todos os valores da ACF ficam próximos de zero
  → isso indica que **não há relação consistente entre passado e presente**
  → a série se comporta como ruído
- Se alguns lags aparecem com valores mais altos
  → isso indica que **existe algum nível de dependência temporal**
  → o passado ainda carrega informação útil

Intuição prática:

- Você está basicamente testando se existe “memória” na série
- Se não tiver memória → não tem muito o que modelar

> “Tem informação no passado ou estou olhando só pra aleatoriedade?”

▼ 2. Diagnosticar o tipo de comportamento

O que você observa:

- Não é só se tem dependência, mas **como ela se comporta ao longo do tempo**
- Ou seja: como a ACF “vai diminuindo” conforme os lags aumentam

Dois padrões clássicos:

- **ACF cai rápido**
  - O primeiro lag pode ser relevante, mas logo depois tudo some
  - Isso indica que o efeito do passado é **curto e localizado**

    > O mercado “absorve” a informação rapidamente

  - **ACF cai devagar**
    - Vários lags continuam relevantes
    - Isso indica uma dependência mais **persistente**

Intuição:

> O impacto do passado continua influenciando por mais tempo

> “O passado influencia só um pouco ou continua influenciando por vários períodos?”

▼ 3. Detectar volatilidade*

O que você faz:

- Em vez de olhar o retorno, você olha:
  - retornos²

O que você quer responder:

> “Períodos de alta volatilidade tendem a continuar sendo voláteis?”

O que costuma acontecer no mercado:

- ACF dos retornos → geralmente ≈ 0
- ACF dos retornos² → costuma mostrar padrão

Interpretação:

- Existe **cluster de volatilidade**
- Ou seja: períodos calmos e períodos turbulentos tendem a se agrupar

Intuição prática:

> O mercado entra em “fases”, e essas fases persistem por um tempo

Tradução simples:

> “Quando o mercado fica agitado, ele tende a continuar agitado?”

Ação:

- Isso justifica o uso de GARCH

▼ 4. Como usar?

▼ Estacionariedade

ACF e PACF assumem que a série tem **estrutura estável ao longo do tempo** (média, variância e relações constantes).

$$ln\left(\frac{P_t}{P_{t-1}}\right)$$

- **ACF ≈ 0 em retornos**
  → comportamento próximo de aleatório
  → o passado não ajuda a prever o presente
- **ACF com padrão (lags relevantes)**
  → existe dependência temporal
  → o passado ainda carrega informação

- **PACF ≈ 0 em todos os lags**
  → não há influência direta significativa
  → reforça a ideia de aleatoriedade
- **PACF com poucos lags relevantes**
  → existe dependência direta simples
  → apenas alguns períodos passados realmente importam
- **PACF com vários lags relevantes**
  → estrutura mais complexa
  → múltiplos períodos têm influência direta

- **ACF mostra padrão, PACF não**
  → dependência pode ser indireta
- **ACF e PACF mostram padrão nos mesmos lags**
  → existe dependência direta real
- **Ambos ≈ 0**
  → série aleatória (sem estrutura linear útil)

▼ 5. Exemplo pratico:

https://github.com/Thiagoooo151/LMF---ARF-PACF