TESE ESTRATÉGICA

Adaptive Multi-Factor Regime-Switching

Quantitative Research

May 13, 2026

Resumo Executivo

A presente estratégia propõe uma abordagem sofisticada de alocação dinâmica de capital através da combinação de três pilares: (i) detecção de regime de mercado via Hidden Markov Model, (ii) exposição a múltiplos fatores quantificados, e (iii) ensemble machine learning para previsão de retornos. A hipótese central é que mercados não são homogêneos—diferentes regimes (bull, bear, high-volatility) requerem alocações distintas para otimizar o tradeoff risco-retorno.

1 Fundamento Teórico

1.1 Hipótese 1: Multi-Fator de Fama-French

Baseamo-nos na extensão empírica do CAPM proposta por Fama & French (2015). Retornos esperados são explicados por exposição a fatores sistêmicos:

$$E[R_i] = R_f + \beta_{market} \cdot \lambda_{market} + \beta_{value} \cdot \lambda_{value} + \beta_{momentum} \cdot \lambda_{momentum} + \varepsilon_i$$

Onde:

- β_{value}: exposição ao fator VALUE (high book-to-market)
- $\beta_{momentum}$: exposição ao fator MOMENTUM (retornos passados de 12m)
- λ: prêmio de risco associado a cada fator
- ε_i: alfa específico do ativo

Intuição: Ativos com elevado book-to-market oferecem maior retorno esperado (fator value). Ativos com momentum positivo tendem a continuar subindo (fator momentum).

1.2 Hipótese 2: Detecção de Regime via HMM

Markets exibem diferentes regimes de volatilidade e tendência. Modelamos isso como um processo Markoviano latente com 3 estados:

$$s_t \in \{\text{Bull}, \text{Bear}, \text{HighVol}\}$$

Cada estado é caracterizado por distribuição específica de retornos e volatilidade:

$$r_t \mid s_t = i \sim \mathcal{N}(\mu_i, \sigma_i^2)$$

Regime	μ_i (retorno médio)	σ_i (volatilidade)	Duração típica
Bull	+0.08%/dia	0.8%	3-6 meses
Bear	−0.06%/dia	1.2%	2-4 meses
HighVol	+0.02%/dia	2.0%	1-2 meses

1.3 Hipótese 3: Machine Learning para Previsão

Combina dois modelos para captar relações não-lineares entre fatores e retornos:

1.3.1 Gradient Boosting

Modelo não-paramétrico que iterativamente reduz erros residuais. Captura interações complexas entre fatores.

1.3.2 Ridge Regression

Modelo linear regularizado. Oferece estabilidade e interpretabilidade. Complementa GBM em regimes com relações lineares.

Ensemble Weights:

$$\hat{r}_t = w_{GB} \cdot \hat{r}_{GB,t} + w_{Ridge} \cdot \hat{r}_{Ridge,t}$$

Onde pesos (w_{GB}, w_{Ridge}) variam conforme regime detectado para maximizar sharpe ratio esperado.

1.4 Hipótese 4: Otimização Dinâmica

Portfolio é otimizado usando mean-variance com restrições dinâmicas:

$$\max_w \quad w^T \hat{\mu} - \frac{\lambda}{2} w^T \Sigma w$$

Sujeito a:

$$\sum_i w_i \leq 1 + \text{leverage}(s_t) \tag{1}$$

$$|w_i| \leq w_{max}(s_t) \tag{2}$$

$$|\Delta w| \leq \text{turnover}_{\max} \tag{3}$$

Leverage dinâmico por regime:

- Bull: leverage = 1.3 (tomar risco adicional)
- Bear: leverage = 0.7 (reduzir exposição)
- HighVol: leverage = 1.0 (posição neutra)

2 Justificativa Teórica

2.1 Por que múltiplos fatores?

Fatores individuais são instáveis. Combinação reduz risco idiossincrático:

$$\text{Volatilidade idiossincrática} \propto \frac{1}{\sqrt{n_{\text{fatores}}}}$$

2.2 Por que regime detection?

Regimes definem estrutura de covariância:

$$\Sigma_t = f(s_t) \implies \text{Otimização depende de } s_t$$

Durante market crashes, correlações explodem. HMM antecipa regime antes de ser tarde demais.

2.3 Por que ensemble ML?

Relação entre fatores e retornos muda conforme regime. Ensemble capta:

- Linearidade em regimes estáveis (Ridge)
- Não-linearidade em inflexões de regime (GBM)

3 Vantagens Competitivas

1. **Adaptativo**: Ajusta agressividade conforme regime, evitando over-leverage em crashes
2. **Diversificado**: 7 fatores independentes reduzem tail-risk
3. **Interpretável**: HMM + fatores definem decisões explícitas (não black-box)
4. **Robusto**: Ensemble + regularização reduzem overfitting
5. **Escalável**: Aplicável a qualquer universo de ativos (ações, futuros, cripto)

4 Risks e Limitações

1. **Parameter Estimation Risk**: Estimação de Σ requer suficiente histórico
2. **Regime Misclassification**: HMM pode ser enganado por outliers
3. **Look-Ahead Bias**: Uso de fatores fundamentalistas pode sofrer delay de publicação
4. **Overfitting em ML**: GBM requer validação cruzada rigorosa
5. **Model Risk**: Pressupostos teóricos podem não valer em stress scenarios

5 Próximas Etapas

A presente tese será validada através de:

1. Implementação do modelo em Python
2. Backtest em 3 anos de dados históricos
3. Walk-forward analysis e stress testing
4. Comparação com benchmarks (S&P 500, 60/40 portfolio)