ESPECIFICAÇÃO TÉCNICA DO MODELO

Adaptive Multi-Factor Regime-Switching Implementation

Quantitative Research

May 13, 2026

1 Arquitetura Geral

O modelo é composto por 4 módulos integrados:

Data → Factor Computation → Regime Detection → ML Predictions → Optimization

2 Módulo 1: Computação de Fatores

2.1 Fator VALUE

$$\text{VALUE}_i = \frac{\text{Book Value}_i}{\text{Preço}_i}$$

Assets com elevado book-to-market são undervalued e oferecem maior retorno esperado (valor inverte o ratio).

2.2 Fator MOMENTUM

$$\text{MOM}_i = \sum_{j=1}^{252} r_{i,t-j}$$

Retorno acumulado nos últimos 12 meses. Captura persistência de tendência (winner stocks continuam subindo).

2.3 Fator QUALITY

$$\text{QUALITY}_i = \text{ROE}_i = \frac{\text{Net Income}_i}{\text{Shareholders' Equity}_i}$$

Empresas com elevado ROE apresentam melhor eficiência operacional e crescimento superior.

2.4 Fator LOW-VOLATILITY

$$\text{LOWVOL}_i = \frac{1}{\sigma_i + \epsilon}$$

Inverso da volatilidade realizada. Captura prefência por ativos menos voláteis (risk-averse investors).

2.5 Fator PROFITABILITY

$$\text{PROF}_i = \frac{\text{EBIT}_i}{\text{Total Assets}_i}$$

Retorno sobre ativos operacionais. Indica qualidade intrínseca da empresa.

2.6 Fator GROWTH

$$\text{GROWTH}_i = \frac{\text{Revenue}_{i,t} - \text{Revenue}_{i,t-1}}{\text{Revenue}_{i,t-1}}$$

Taxa de crescimento de receita. Empresas crescentes possuem maior múltiplo de valuation.

2.7 Fator MEAN-REVERSION

$$\text{MEANREV}_i = -\sum_{j=1}^{63} r_{i,t-j}$$

Negativo do retorno acumulado últimos 3 meses. Captura reverter-à-média (quem cai muito tende a subir).

2.8 Normalização de Fatores

Todos os fatores são padronizados:

$$\text{factor}_{\text{normalized}} = \frac{\text{factor} - \text{mean(factor)}}{\text{std(factor)} + \epsilon}$$

Garante que todos os fatores tenham peso comparável na otimização.

3 Módulo 2: Detecção de Regime via HMM

3.1 Especificação do Modelo

Hidden Markov Model com 3 estados latentes:

$$p(s_t, s_{t-1}, \ldots, s_1 \mid r_1, \ldots, r_T) \propto p(r_t \mid s_t) \cdot p(s_t \mid s_{t-1})$$

3.2 Observações (Features)

O HMM usa dois sinais:

$$X_{1,t} = \frac{1}{252} \sum_{j=0}^{251} r_{market,t-j} \quad \text{(média móvel de retornos)} \tag{1}$$

$$X_{2,t} = \sqrt{\frac{1}{252} \sum_{j=0}^{251} r_{market,t-j}^2} \quad \text{(volatilidade móvel)} \tag{2}$$

Ambos são padronizados antes de passar para HMM.

3.3 Transições de Estado

Matriz de transição P modela probabilidade de mudança de regime:

$$P = \begin{pmatrix} p_{11} & p_{12} & p_{13} \\ p_{21} & p_{22} & p_{23} \\ p_{31} & p_{32} & p_{33} \end{pmatrix}$$

Onde $p_{ij} = \Pr(s_t = j \mid s_{t-1} = i)$.

3.4 Viterbi Algorithm

Para recuperar a sequência mais provável de regimes:

$$\hat{s}_{1:T} = \arg\max_{s_{1:T}} \log p(s_{1:T} \mid r_{1:T})$$

Usado para identificar o regime corrente a cada dia.

4 Módulo 3: ML Ensemble para Previsão

4.1 Gradient Boosting Regressor

Treinado com hiperparâmetros otimizados:

- $n_estimators = 200$ (200 árvores)
- $learning_rate = 0.05$ (taxa de aprendizado moderada)
- $max_depth = 5$ (profundidade controlada contra overfitting)
- $subsample = 0.8$ (80% de dados por iteração)

Captura relações não-lineares como:

$$r_{i,t} = f(X_1, X_2, X_3) + \varepsilon_t$$

onde f é aproximada por soma de árvores de decisão.

4.2 Ridge Regression

Minimiza:

$$\min_{\beta} \|y - X\beta\|_2^2 + \alpha\|\beta\|_2^2$$

Com $\alpha = 1.0$. Oferece estabilidade numérica e evita multicolinearidade entre fatores.

4.3 Ensemble Voting

Predições finais combinam ambos os modelos com pesos dependentes do regime:

$$\hat{r}_{i,t} = \begin{cases} 0.6 \cdot \hat{r}_{GB} + 0.4 \cdot \hat{r}_{Ridge} & \text{se } s_t = \text{Bull} \\ 0.4 \cdot \hat{r}_{GB} + 0.6 \cdot \hat{r}_{Ridge} & \text{se } s_t = \text{Bear} \\ 0.5 \cdot \hat{r}_{GB} + 0.5 \cdot \hat{r}_{Ridge} & \text{se } s_t = \text{HighVol} \end{cases}$$

Intuição: Em bear markets, preferimos estabilidade (Ridge). Em bull markets, capturamos não-linearidades (GB).

5 Módulo 4: Otimização de Portfolio

5.1 Formulação

Mean-Variance com restrições dinâmicas:

$$\max_{w} \quad w^T\hat{\mu} - \frac{\lambda}{2} w^T\Sigma w$$

Sujeito a:

$$\sum_i |w_i| \leq L(s_t) \tag{3}$$

$$|w_i| \leq w_{\max}(s_t) \tag{4}$$

$$\|w - w_{t-1}\|_1 \leq \delta_{\max} \tag{5}$$

5.2 Leverage Dinâmico

$$L(s_t) = \begin{cases} 1.3 & \text{Bull (confiança alta)} \\ 0.7 & \text{Bear (reduzir riscos)} \\ 1.0 & \text{HighVol (posição neutra)} \end{cases}$$

5.3 Peso Máximo por Ativo

$$w_{\max}(s_t) = \begin{cases} 0.08 & \text{Bull} \\ 0.05 & \text{Bear} \\ 0.06 & \text{HighVol} \end{cases}$$

Evita concentração excessiva. Mais apertado em bear markets.

5.4 Reescalamento para Target Volatility

Portfolio é ajustado para atingir volatilidade alvo de 8% a.a.:

$$w_{\text{final}} = w_{\text{optimized}} \cdot \frac{\sigma_{\text{target}}}{\sigma_{\text{portfolio}}}$$

Garante que risco é controlado independentemente do retorno esperado.

6 Pipeline Completo

1. **Input:** historical returns, prices and fundamentals.
2. Compute factors using data up to day $t - 1$.
3. Normalize factors to zero mean and unit standard deviation.
4. Run HMM inference to detect regime s_t.
5. Predict returns using the ML ensemble.
6. Estimate covariance matrix Σ_t.
7. Optimize portfolio weights w_t^*.
8. Execute trades to rebalance to w_t^*.
9. Monitor realized returns and update metrics.

7 Validação Cruzada

7.1 Walk-Forward Validation

Para evitar look-ahead bias:

1. Treinar ML em período $[t - 252, t - 20]$ (1 ano de dados, deixando 20 dias de teste)
2. Validar em período $[t - 20, t]$
3. Mover janela para frente 1 dia
4. Repetir para todo o período de backtest

7.2 Stress Testing

Modelo testado em cenários extremos:

- 2008 Financial Crisis (pior caso)
- 2020 COVID Crash (teste de resiliência)
- 2000 Dot-Com Bubble (teste de bear market)

8 Resumo de Complexidade

Componente	**Complexidade**
Computação de Fatores	$O(n \cdot p)$ (linear)
HMM Inference (Viterbi)	$O(T \cdot k^2)$ (quadrática em estados)
ML Training (GBM)	$O(n \log n)$ por iteração
Portfolio Optimization	$O(p^3)$ (inversão de matriz)

Tempo total de execução diária: $\sim 2 - 5$ segundos para 50 ativos.